

Mémoire de Master 1

MIAGE (Initial)

Protection des données personnelles et anonymisation : Comparaison empirique du k-anonymat, de la l-diversité et de la confidentialité différentielle

Présenté et soutenu par

Aziz TLILI

Le 4 Juin 2026

Jury de soutenance

M. Rafael Angarita Arocha	Tuteur du mémoire
Mme Sonia Saadaoui	Directrice du Master

Remerciements

Je remercie mon tuteur de mémoire, M. Rafael Angarita Arocha, pour sa patience et sa bienveillance dans toutes les phases de la finalisation de ce travail.

Mes remerciements s'adressent à Madame Sonia Saadaoui, responsable du Master, pour son soutien et son encadrement tout au long de cette année universitaire.

Ma reconnaissance va aux enseignants du Master 1 qui ont enrichi mes connaissances dans le domaine des systèmes d'information et de la protection des données.

J'exprime enfin ma gratitude envers toutes les personnes qui ont contribué, de près ou de loin, à l'élaboration de ce mémoire, en particulier ma mère qui a porté sa casquette d'universitaire pour m'accompagner dans la construction de la structure et de la méthodologie.

Résumés

L'objectif de ce mémoire est de comparer trois techniques d'anonymisation : le k-anonymat, la l-diversity et la confidentialité différentielle. Cette comparaison s'appuie sur quatre critères principaux : le risque de réidentification, l'utilité des données, la complexité d'implémentation et la conformité réglementaire au regard des exigences du RGPD.

Après une revue de littérature consacrée aux fondements théoriques de l'anonymisation, aux principales attaques contre les données anonymisées et au compromis confidentialité-utilité, une expérimentation a été réalisée sur le dataset UCI Adult Census Income, issu du recensement américain.

L'analyse comparative met en évidence qu'aucune technique n'est supérieure dans toutes les situations. Le k-anonymat se distingue par sa simplicité, la l-diversity par sa meilleure protection des attributs sensibles et la confidentialité différentielle par son excellente capacité à concilier confidentialité, utilité des données et conformité réglementaire. Ces résultats confirment que le choix d'une technique d'anonymisation doit être réalisé en fonction du contexte d'utilisation, du niveau de risque acceptable et des objectifs poursuivis.

Mots-clés : Anonymisation des données, protection de la vie privée, k-anonymat, l-diversity, confidentialité différentielle, RGPD, réidentification, privacy-utility tradeoff, UCI Adult Census Income.

Abstract

The objective is to compare three major data anonymization techniques : k-anonymity, l-diversity, and differential privacy. The comparison is based on four main criteria : re-identification risk, data utility, implementation complexity, and regulatory compliance with the requirements of the General Data Protection Regulation (GDPR).

Following a literature review focusing on the theoretical foundations of data anonymization, the main attacks against anonymized data, and the privacy-utility trade-off, an experimental study was conducted using the UCI Adult Census Income dataset derived from the United States Census.

The comparative analysis highlights that no single technique is superior in all situations. K-anonymity stands out for its simplicity, l-diversity for its enhanced protection of sensitive attributes, and differential privacy for its strong ability to balance privacy protection, data utility, and regulatory compliance. These findings confirm that the choice of an anonymization technique should depend on the specific context of use, the acceptable level of risk, and the objectives pursued.

Keywords : Data anonymization, privacy protection, k-anonymity, l-diversity, differential privacy, GDPR, re-identification, privacy-utility trade-off.

Table des matières

Remerciements	2
Résumés	3
1 Méthodologie de la revue de littérature	6
1.1 Justification du choix du sujet	6
1.2 Justification du choix des techniques étudiées	7
1.3 Spécification de la question de recherche : la méthode PICOC	7
1.4 Revue systématique de littérature	8
1.5 Résultats de la recherche d'articles	8
1.6 Organisation et classement des articles	9
Introduction	10
2 L'anonymisation des données	11
2.1 Définition	11
2.2 Cadre réglementaire de la protection des données	12
2.3 Le k-anonymat	12
2.3.1 Limites du k-anonymat	13
2.4 La l-diversity	13
2.5 La confidentialité différentielle	14
2.6 Les attaques contre les données anonymisées	14
2.7 Le compromis confidentialité-utilité (<i>Privacy-Utility Tradeoff</i>)	15
3 Méthodologie d'application des techniques d'anonymisation	16
3.1 Analyse des alternatives envisagées	16
3.2 Présentation de la base de données retenue : UCI Adult Census Income	17
3.3 Attributs retenus pour l'expérimentation	17
3.4 Critères de comparaison retenus	18
3.4.1 Risque de réidentification	18
3.4.2 Utilité des données	18
3.4.3 Complexité d'implémentation	19
3.4.4 Conformité réglementaire	19
3.5 Processus d'implémentation	19
3.6 Environnement technique	20
3.6.1 Choix de l'environnement Python	20
4 Analyse comparative des techniques d'anonymisation	21
4.1 Diagnostic initial du dataset	21
4.1.1 Analyse des quasi-identifiants	21

4.1.2	Analyse de l'attribut sensible	22
4.2	Résultats du k-anonymat	22
4.3	Résultats de la l-diversity	25
4.4	Résultats de la confidentialité différentielle	26
4.5	Analyse comparative des trois techniques	28
4.5.1	Comparaison selon la protection de la vie privée	28
4.5.2	Comparaison selon l'utilité des données	29
4.5.3	Comparaison selon la complexité d'implémentation et la confor- mité réglementaire	29
4.6	Discussion des résultats	30
4.7	Limites de l'expérimentation	31
Conclusion générale		32
Bibliographie		33

Chapitre 1

Méthodologie de la revue de littérature

1.1 Justification du choix du sujet

Le point de départ du sujet a été ma volonté d’aborder les principales techniques d’anonymisation des données. En effet, le développement du Big data et de l’intelligence artificielle a rendu importante la quantité de données collectées, stockées et exploitées. Ces données constituent des informations précieuses pour la prise de décision, l’innovation et le développement de nouveaux services. Toutefois, leur utilisation peut compromettre la protection de la vie privée et la sécurité des individus.

Ainsi, l’anonymisation des données est l’une des meilleures solutions permettant à la fois de préserver l’utilité des données et de protéger les personnes contre les risques de réidentification et de divulgation d’informations sensibles.

L’intérêt du sujet réside dans le fait que les techniques d’anonymisation ont connu une évolution importante. Il y eut d’abord des approches fondées sur la généralisation des données, telles que le k -anonymat et ses extensions, puis les méthodes probabilistes comme la confidentialité différentielle. Cette diversité des approches rend nécessaire une analyse comparative permettant de mieux comprendre leurs avantages, leurs limites et leurs domaines d’application.

Par ailleurs, l’entrée en vigueur du Règlement Général sur la Protection des Données (**RGPD**) a imposé aux entreprises de mettre en œuvre des mécanismes garantissant une protection des données personnelles. Les autorités de régulation, telles que la CNIL ou le Comité Européen de la Protection des Données, ont insisté sur la nécessité d’évaluer le risque de réidentification avant toute diffusion ou exploitation de données anonymisées.

L’évolution des menaces, le développement des capacités de calcul, la multiplication des bases de données ouvertes et le développement de l’intelligence artificielle ont fait apparaître de nouvelles formes d’attaques et de réidentification, remettant en question l’efficacité de certaines méthodes. Il devient donc essentiel de comparer les différentes solutions disponibles afin d’identifier les conditions dans lesquelles elles permettent de protéger la vie privée. La comparaison empirique des principales techniques d’anonymisation contribue ainsi à orienter le choix de la technique la plus appropriée.

1.2 Justification du choix des techniques étudiées

Le k-anonymat, la l-diversité et la confidentialité différentielle sont historiquement très importants dans la littérature. Ces trois méthodes constituent les références les plus citées dans le domaine de l'anonymisation des données.

Le k-anonymat, introduit par Latanya Sweeney, représente le premier modèle largement adopté pour réduire les risques de réidentification à partir des quasi-identifiants. Toutefois, les travaux ultérieurs ont mis en évidence sa vulnérabilité aux attaques d'homogénéité. Afin de répondre à ces limites, Ashwin Machanavajjhala et ses collaborateurs ont proposé la l-diversité, qui constitue une extension directe du k-anonymat. Cette approche renforce la protection des attributs sensibles en imposant une diversité minimale des valeurs sensibles au sein de chaque groupe anonymisé.

La confidentialité différentielle, introduite par Cynthia Dwork, repose sur un cadre probabiliste offrant des garanties mathématiques indépendantes des connaissances de l'attaquant. Elle est aujourd'hui adoptée par de nombreuses institutions et organisations, notamment pour les environnements de données massives et les applications d'intelligence artificielle.

Le choix de ces trois techniques permet de comparer une approche fondée sur l'anonymisation par généralisation (k-anonymat), une approche qui protège les attributs sensibles (l-diversité) et une approche probabiliste qui offre des garanties de confidentialité (confidentialité différentielle). Par ailleurs, ces trois méthodes sont particulièrement adaptées à l'objectif de cette recherche puisqu'elles peuvent être appliquées à des données tabulaires structurées. Enfin, leur comparaison permet d'évaluer les arbitrages entre la réduction du risque de réidentification, la préservation de l'utilité des données, la complexité d'implémentation et la conformité aux exigences du RGPD.

1.3 Spécification de la question de recherche : la méthode PICOC

De ces principaux constats, j'ai pu spécifier les questions de recherche que je me propose d'aborder. J'ai également pu structurer et délimiter le périmètre de la revue de littérature grâce à la méthode PICOC.

- **RQ1** : Quelles sont les principales techniques d'anonymisation des données ?
- **RQ2** : Comment le k-anonymat, la l-diversité et la confidentialité différentielle réduisent-ils le risque de réidentification ?
- **RQ3** : Quelles sont les étapes nécessaires pour transformer les données brutes en données anonymisées pour chacune des méthodes retenues ?
- **RQ4** : Quels sont les indices à retenir pour comparer la performance des méthodes retenues à préserver l'anonymat ?
- **RQ5** : Quelle technique semble la plus adaptée selon les différents contextes d'utilisation des données ?

TABLE 1.1 – Éléments de la méthode PICOC

Élément	Définition
Population	Jeux de données contenant des données personnelles
Intervention	Techniques d'anonymisation
Comparison	k-anonymity, l-diversity, Differential Privacy
Outcome	Confidentialité, utilité, risque de ré-identification
Context	Partage et exploitation de données tabulaires

1.4 Revue systématique de littérature

Afin de collecter les différents articles permettant de répondre à la question de recherche, j'ai eu recours à une revue structurée. Dans le cadre du cours suivi, plusieurs plateformes ont été proposées.

Critères d'inclusion :

Les articles retenus contiennent les mots-clés suivants :

"K-anonymity" OR "L-diversity" OR "Differential privacy"
 AND
 "Privacy utility tradeoff" OR "data utility" OR "information loss"
 AND
 "Data anonymization" OR "privacy preserving data publishing"

- Articles rédigés en anglais ou en français
- Articles en open access
- Articles issus de sources scientifiquement reconnues (Scopus, Dimensions, Google Scholar)
- Articles publiés entre 2016 et 2026

Critères d'exclusion :

- Les articles ne portant pas sur l'anonymisation des données (cybersécurité, authentification, chiffrement)
- Les articles ne traitant pas du k-anonymity, de la l-diversity ou de la Differential Privacy
- Les résumés de conférences sans article complet et les présentations PowerPoint
- Les doublons
- Les articles hors contexte (anonymisation d'images, reconnaissance faciale, données audio)
- Les articles dont le texte intégral n'est pas accessible

1.5 Résultats de la recherche d'articles

1. **Google Scholar** : Introduction de l'ensemble des mots-clés avec spécification de la période 2016–2026 et prise en compte des articles de revue. 466 articles proposés. Google Scholar ne permettant pas de filtrer par critère open access ou hors-contexte, un article parfaitement aligné avec la question de recherche a pu être retenu comme point de départ pour le processus de *snowballing*.

2. **Dimensions AI** : Introduction des mots-clés dans les titres et résumés ; filtrage par critères d'inclusion et d'exclusion (période, type de publication, open access) ; ajout de la discipline *Information and Computing Science*. 42 publications proposées.
3. **Scopus** : Application des mêmes mots-clés et critères de filtrage. 6 publications proposées.
4. **Connected Papers** : L'article de Kara, Eyupoglu et Karaku (2025) [11], parfaitement aligné avec la question de recherche, a servi de point d'entrée. La recherche sur la plateforme Connected Papers a permis de recenser les articles connexes en termes de contenu et de convergence. Ci-après le lien du graphe obtenu :

[https://www.connectedpapers.com/main/
1fb2bc57e0fd2772907be15d4514a68fb81384d9/Connected-Papers-%
7C-Find-and-explore-academic-papers/graph](https://www.connectedpapers.com/main/1fb2bc57e0fd2772907be15d4514a68fb81384d9/Connected-Papers-%7C-Find-and-explore-academic-papers/graph)

Le processus de filtrage par critères d'inclusion/exclusion a permis d'obtenir 8 articles supplémentaires.

Tous les articles obtenus ont fait l'objet d'une lecture des résumés afin d'évaluer leur pertinence, puis d'une lecture approfondie en vue de la synthèse. Au total, 20 articles ont été essentiellement retenus. Les articles de base des méthodes ont également été inclus malgré leur date de publication ancienne : Sweeney (2002) [18] pour le k-anonymat, Machanavajjhala et al. (2007) [14] pour la l-diversity et Dwork et al. (2006) [2] pour la confidentialité différentielle.

1.6 Organisation et classement des articles

L'ensemble des articles téléchargés a fait l'objet d'une classification facilitant la rédaction de la synthèse et de la bibliographie. Zotero a permis de créer des rubriques pour chaque sous-thème spécifié et d'introduire le DOI de chaque article pour l'intégrer dans la bibliothèque. Cette organisation a assuré une traçabilité rigoureuse des sources tout au long de la rédaction.

Introduction

L'anonymisation des données constitue aujourd'hui un élément indispensable afin de protéger la vie privée dans les environnements numériques. Face à l'augmentation des volumes de données collectées, la nécessité de partager et d'exploiter ces informations tout en préservant la confidentialité des individus est devenue un enjeu majeur. L'anonymisation vise précisément à répondre à ce défi en réduisant le risque qu'une personne puisse être identifiée directement ou indirectement à partir d'un jeu de données [4].

Depuis, plusieurs techniques d'anonymisation ont vu le jour, certaines présentant des limites que d'autres essaient de neutraliser. Mais la recherche antérieure n'est pas parvenue à trancher quant à la supériorité d'une technique sur l'autre dans la protection tout en préservant un niveau d'utilité acceptable [9].

L'objectif de ce mémoire est de comparer certaines techniques d'anonymisation afin de voir si, en fonction du contexte de l'étude, une technique présente de meilleures performances en termes de compromis confidentialité-utilité. Le choix s'est porté sur trois techniques : le k-anonymat, la l-diversité et la confidentialité différentielle. Le choix de ces méthodes a été justifié dans le chapitre précédent.

La question de recherche pour laquelle je me propose d'apporter une réponse est la suivante :

Dans quelle mesure les techniques d'anonymisation retenues permettent de concilier protection de la vie privée et utilité analytique des données, et quelles différences de performances empiriques présentent-elles ?

Le chapitre suivant propose les principes fondamentaux des différentes techniques retenues ainsi que la littérature antérieure sur la comparaison, les différents indices de performance et les dimensions du risque de réidentification. Une section sera également consacrée au cadre réglementaire de la protection des données. Le chapitre 4 présente les choix méthodologiques et les différentes étapes suivies pour anonymiser les données par chacune des méthodes retenues. Le dernier chapitre sera consacré à la discussion des résultats obtenus ainsi qu'à l'ouverture pour de futures recherches.

Chapitre 2

L'anonymisation des données

2.1 Définition

Le principe de l'anonymisation consiste à transformer les données de manière à empêcher l'identification des individus tout en conservant une utilité suffisante pour les analyses statistiques, la recherche scientifique ou la prise de décision. Cette démarche repose sur l'idée qu'il est possible de protéger la vie privée sans supprimer toute valeur informative des données. L'objectif est donc de trouver un équilibre entre deux exigences souvent contradictoires : la confidentialité et l'utilité des données.

Pour comprendre les mécanismes de l'anonymisation, on distingue plusieurs catégories d'attributs présents dans une base de données.

- **Les identifiants directs** correspondent aux informations permettant d'identifier immédiatement une personne, telles que le nom, le numéro de carte d'identité, le numéro de sécurité sociale ou l'adresse électronique. Ces attributs sont généralement supprimés avant toute diffusion des données.
- **Les quasi-identifiants** sont des informations qui ne permettent pas, à elles seules, d'identifier un individu, mais qui peuvent conduire à une réidentification lorsqu'elles sont combinées avec d'autres sources d'information. Parmi les exemples les plus courants figurent l'âge, le sexe, le code postal, la profession ou la date de naissance. Ces attributs constituent souvent la principale cible des techniques d'anonymisation.
- **Les attributs sensibles** regroupent les informations dont la divulgation pourrait porter atteinte à la vie privée des individus. Il peut s'agir de données médicales, financières, génétiques, religieuses ou relatives aux opinions politiques. La protection de ces attributs constitue l'un des objectifs fondamentaux des modèles d'anonymisation.

Les techniques d'anonymisation reposent sur plusieurs mécanismes de transformation : la **suppression** consiste à retirer certaines informations jugées trop sensibles ou identifiantes ; la **généralisation** remplace une valeur précise par une catégorie plus large, par exemple en transformant un âge exact en tranche d'âge ; la **perturbation** modifie certaines valeurs en introduisant un bruit contrôlé afin de réduire les risques de réidentification. D'autres approches plus récentes utilisent la génération de données synthétiques ou l'ajout de bruit statistique selon les principes de la confidentialité différentielle.

L'efficacité d'une technique d'anonymisation est généralement évaluée selon trois critères principaux : le niveau de protection de la vie privée, c'est-à-dire la capacité du mécanisme à limiter les risques de réidentification ; l'utilité des données, qui mesure

dans quelle mesure les données anonymisées conservent leur valeur analytique ; et le **compromis confidentialité-utilité**, considéré aujourd'hui comme l'un des enjeux centraux de la recherche en protection des données.

2.2 Cadre réglementaire de la protection des données

Les législateurs ont mis en place des cadres réglementaires destinés à protéger les personnes contre les risques liés à l'utilisation abusive de leurs données personnelles. La protection des données personnelles repose sur un principe fondamental : les individus doivent conserver un certain contrôle sur les informations qui les concernent.

Le texte de référence le plus influent est le **Règlement Général sur la Protection des Données (RGPD)**, adopté par l'Union européenne en 2016 et appliqué depuis le 25 mai 2018. Le RGPD définit les données personnelles comme toute information se rapportant à une personne physique identifiée ou identifiable. Il repose sur plusieurs principes fondamentaux : la licéité, la loyauté et la transparence du traitement ; la limitation des finalités ; la minimisation des données ; l'exactitude ; la limitation de la durée de conservation ; l'intégrité et la confidentialité ; ainsi que la responsabilité des organisations.

L'anonymisation dans le cadre du RGPD établit une distinction importante entre anonymisation et pseudonymisation. Les données anonymisées ne permettant plus d'identifier une personne de manière irréversible sortent du champ d'application du RGPD. Les données pseudonymisées, en revanche, restent des données personnelles car une réidentification reste théoriquement possible.

D'autres cadres réglementaires encadrent la protection des données à travers le monde : le **HIPAA** aux États-Unis pour les données de santé, le **CCPA** en Californie, le **UK GDPR** au Royaume-Uni, le **PIPEDA** au Canada et la **LGPD** au Brésil.

Les progrès des technologies d'analyse de données, l'augmentation des capacités de calcul et la disponibilité croissante de données publiques accroissent les risques de réidentification. Une donnée considérée comme anonymisée aujourd'hui pourrait potentiellement être réidentifiée demain grâce à de nouvelles sources d'information ou à des techniques d'analyse plus performantes.

2.3 Le k-anonymat

Le k-anonymat constitue l'une des premières approches formelles développées pour protéger la vie privée lors du partage de données individuelles. Introduite par Sweeney [18], cette technique est née du constat que la simple suppression des identifiants directs ne suffit pas à garantir l'anonymat des personnes concernées.

Le principe fondamental du k-anonymat repose sur l'idée qu'un individu ne doit pas pouvoir être distingué d'au moins $k - 1$ autres personnes présentes dans la base de données. Autrement dit, chaque enregistrement doit appartenir à un groupe contenant au minimum k individus partageant les mêmes caractéristiques de quasi-identifiants. Pour atteindre cet objectif, le k-anonymat utilise principalement la **généralisation** et la **suppression**. Par exemple, une date de naissance complète peut être remplacée par une année de naissance ou une tranche d'âge.

L'apport majeur du k-anonymat est de réduire significativement les risques de réidentification par liaison de données (*linkage attacks*). Cependant, malgré son impor-

tance historique, le k-anonymat présente certaines limites qui ont conduit au développement d'extensions telles que la l-diversity et la t-closeness [7].

2.3.1 Limites du k-anonymat

1. **Vulnérabilité aux attaques d'homogénéité.** Lorsque tous les individus d'un même groupe anonymisé possèdent la même valeur sensible, un attaquant peut déduire cette information avec certitude, même sans identifier précisément la personne concernée.
2. **Vulnérabilité aux attaques par connaissances externes.** Dans la réalité, un individu malveillant peut combiner les données anonymisées avec des connaissances externes, telles que des informations publiques ou des données issues des réseaux sociaux.
3. **Forte perte d'information.** Pour atteindre un niveau élevé de k-anonymat, il est souvent nécessaire de généraliser ou de supprimer un grand nombre de données, réduisant leur utilité analytique.
4. **Difficulté à gérer les données de grande dimension.** Lorsque les jeux de données comportent de nombreuses variables, la généralisation nécessaire devient excessive, entraînant une dégradation de la qualité des données.
5. **Absence de garantie mathématique de confidentialité.** Le k-anonymat ne fournit pas de garantie formelle quantifiable contre toutes les formes d'attaques. Son niveau de protection dépend des connaissances de l'attaquant et des sources de données externes disponibles.
6. **Sensibilité aux publications successives.** Lorsque plusieurs versions d'un même jeu de données sont publiées dans le temps, un attaquant peut comparer ces différentes versions et en déduire des informations supplémentaires.

2.4 La l-diversity

Machanavajjhala et al. (2007) [14] ont proposé le modèle de la **l-diversity**, considéré comme l'une des extensions les plus influentes du k-anonymat. Leur objectif était de renforcer la confidentialité des données en s'assurant que chaque groupe anonymisé contienne une diversité suffisante de valeurs sensibles.

Le principe fondamental de la l-diversity repose sur l'idée que les informations sensibles associées aux individus doivent être suffisamment variées. Ainsi, même si un attaquant parvient à déterminer le groupe auquel appartient une personne, il ne pourra pas déduire avec certitude son information sensible. Par exemple, dans une base de données médicales, un groupe peut satisfaire les exigences du k-anonymat mais si tous ses membres souffrent de la même maladie, la confidentialité demeure compromise. La l-diversity cherche précisément à éviter cette situation.

Cependant, la l-diversity présente également certaines limites. Son application peut entraîner une perte d'information plus importante que celle observée avec le k-anonymat, notamment lorsque les données contiennent des catégories rares ou lorsque certaines valeurs sensibles sont fortement déséquilibrées. Dans certains contextes, une diversité apparente peut masquer une faible protection réelle lorsque les valeurs sensibles restent très similaires d'un point de vue sémantique [13].

2.5 La confidentialité différentielle

Dwork et al. (2006) [2] ont introduit le concept de **confidentialité différentielle** (*Differential Privacy*). Aujourd'hui, cette approche est largement considérée comme l'une des méthodes les plus avancées en matière de protection de la vie privée. Son objectif est de garantir que la présence ou l'absence d'une personne dans un jeu de données n'influence pas significativement les résultats publiés. En d'autres termes, un attaquant ne doit pas être en mesure de déterminer si les informations d'un individu particulier ont été utilisées ou non dans une analyse.

Pour atteindre cet objectif, la confidentialité différentielle introduit volontairement une certaine quantité d'aléa dans les résultats produits, en ajoutant un bruit statistique contrôlé aux requêtes, aux statistiques ou aux modèles générés à partir des données originales.

L'un des concepts centraux de la confidentialité différentielle est le **budget de confidentialité**, généralement représenté par le paramètre ε (epsilon). Ce paramètre contrôle le niveau de protection accordé aux individus. Une valeur faible de ε correspond à une protection élevée mais peut entraîner une perte d'utilité plus importante. À l'inverse, une valeur élevée préserve davantage la précision des résultats mais réduit le niveau de confidentialité.

De grandes organisations technologiques ont adopté cette approche. Des entreprises comme Apple, Google et Microsoft utilisent des mécanismes inspirés de la confidentialité différentielle pour collecter et analyser certaines données utilisateur tout en limitant les risques d'atteinte à la vie privée [3]. Malgré ses nombreux avantages, la confidentialité différentielle présente des limites : l'ajout de bruit peut réduire la précision des analyses, en particulier lorsque les jeux de données sont de petite taille, et le choix approprié du budget de confidentialité demeure un sujet de débat dans la littérature.

2.6 Les attaques contre les données anonymisées

Les progrès réalisés dans le domaine de l'anonymisation ont permis de développer des mécanismes de protection de plus en plus sophistiqués. Toutefois, plusieurs travaux récents soulignent qu'aucune technique ne garantit une protection absolue. Dans une revue exhaustive des menaces sur la confidentialité numérique, Song et al. (2025) [17] montrent que les attaques ciblant les données anonymisées peuvent prendre différentes formes :

- **Attaques par liaison** (*Linkage Attacks*) : consistant à croiser un jeu de données anonymisé avec des sources d'information externes afin de réidentifier des individus ou de révéler des informations sensibles.
- **Attaques structurelles** (*Structural Attacks*) : exploitant la structure, les relations ou les caractéristiques internes d'un jeu de données pour déduire l'identité ou les attributs d'une personne.
- **Attaques de reconstruction** (*Reconstruction Attacks*) : visant à reconstituer tout ou partie des données originales à partir de statistiques, de données agrégées ou de résultats publiés.
- **Attaques d'inférence** (*Inference Attacks*) : permettant de déduire des informations sensibles sur un individu en exploitant les corrélations et les connaissances disponibles, même sans accès direct aux données.

Ces constats justifient l'émergence de modèles de protection plus avancés tels que le k-anonymat, la l-diversity, la t-closeness et la confidentialité différentielle. Ils soulignent

également l'importance d'évaluer toute technique d'anonymisation en termes de protection théorique et en fonction de sa résistance aux différentes catégories d'attaques.

2.7 Le compromis confidentialité-utilité (*Privacy–Utility Tradeoff*)

L'un des défis fondamentaux de l'anonymisation des données réside dans la recherche d'un équilibre entre la protection de la vie privée et la préservation de l'utilité des données. Cette problématique, connue sous le nom de **Privacy–Utility Tradeoff**, constitue aujourd'hui l'un des principaux axes de recherche dans le domaine de la protection des données personnelles [10, 9].

En effet, l'objectif de toute technique d'anonymisation est double. D'une part, elle doit réduire les risques de réidentification et protéger les informations sensibles. D'autre part, elle doit conserver suffisamment d'informations pour permettre l'exploitation des données à des fins d'analyse, de recherche ou de prise de décision. Ces deux objectifs sont cependant souvent contradictoires [9].

Ce compromis apparaît clairement dans les principales techniques d'anonymisation. Dans le cas du k -anonymat, l'augmentation de la valeur de k nécessite souvent une généralisation plus importante des quasi-identifiants [12, 10]. La l -diversity renforce la protection des attributs sensibles en imposant une plus grande diversité, mais au prix d'une perte d'information [13]. Quant à la confidentialité différentielle, plus le niveau de confidentialité recherché est élevé, plus la quantité de bruit ajoutée est importante.

La littérature récente considère désormais que la question est de déterminer le meilleur équilibre possible entre confidentialité et utilité. Ce constat est particulièrement important dans les domaines sensibles tels que la santé, la finance ou les services publics, où les données doivent simultanément être protégées et rester exploitables [9].

Chapitre 3

Méthodologie d'application des techniques d'anonymisation

Après avoir présenté les fondements théoriques de l'anonymisation des données et analysé les caractéristiques des techniques retenues, j'ai souhaité confronter ces approches à un jeu de données réel afin d'observer leur fonctionnement concret. Cette démarche me semblait indispensable pour compléter la revue de littérature : lire ce que les techniques font théoriquement est une chose, les voir à l'œuvre sur des données réelles en est une autre.

L'objectif de cette démarche n'est pas de proposer une nouvelle méthode d'anonymisation ni de développer un algorithme original. Il s'agit d'évaluer, dans un cadre contrôlé et reproductible, les effets des principales techniques étudiées sur plusieurs dimensions essentielles : la réduction du risque de réidentification, la préservation de l'utilité des données, la facilité de mise en œuvre et la conformité aux exigences réglementaires.

3.1 Analyse des alternatives envisagées

Avant de me lancer dans l'expérimentation, j'ai dû me poser une question fondamentale : sur quel dataset travailler ? Ce choix n'a pas été immédiat, et plusieurs alternatives ont été sérieusement envisagées.

Les bases de données médicales constituent un terrain pertinent pour l'étude des mécanismes d'anonymisation en raison de la sensibilité des informations qu'elles contiennent. Parmi elles, la base MIMIC-III est largement utilisée dans la recherche académique. Toutefois, son accès nécessite l'obtention d'autorisations spécifiques ainsi que la validation d'une formation en éthique de la recherche. Ces contraintes de temps et de procédure m'ont conduit à écarter cette option, même si elle aurait été particulièrement riche sur le plan scientifique.

Les bases de données financières réelles ont également été envisagées. Cependant, les données transactionnelles bancaires sont généralement protégées par des obligations de confidentialité et ne sont pas librement accessibles aux chercheurs. Les alternatives disponibles reposent souvent sur des données simulées, dont l'utilisation aurait limité la portée de l'étude.

Les jeux de données synthétiques ont aussi été considérés. Bien qu'ils offrent une grande flexibilité, les utiliser pour illustrer des mécanismes de réidentification aurait soulevé une difficulté méthodologique : démontrer l'efficacité de techniques d'anonymisation sur des données artificiellement générées aurait réduit le réalisme et la portée de

l'analyse.

Les données issues de recensements publics sont finalement apparues comme la solution la plus adaptée. Elles présentent l'avantage d'être facilement accessibles, de contenir de nombreux attributs démographiques et socio-économiques et d'être largement utilisées dans les travaux de recherche consacrés à la protection des données personnelles. C'est ce qui m'a conduit à retenir le dataset UCI Adult Census Income.

3.2 Présentation de la base de données retenue : UCI Adult Census Income

Le dataset UCI Adult Census Income, également connu sous les appellations *Adult* ou *Census Income* [1], est un jeu de données disponible au sein de l'UCI Machine Learning Repository, l'une des plateformes de référence les plus utilisées par la communauté scientifique pour le développement et l'évaluation des méthodes d'analyse de données et d'apprentissage automatique.

Ce qui m'a convaincu d'utiliser ce dataset, c'est qu'il réunit plusieurs qualités rarement réunies : il est librement accessible, ne nécessite aucune procédure d'autorisation particulière, contient un ensemble riche et réaliste de quasi-identifiants permettant d'illustrer les mécanismes de réidentification, et dispose d'un attribut sensible clairement identifié (le revenu). Par ailleurs, il a notamment servi de support à plusieurs travaux fondateurs sur le k-anonymat et la l-diversity, tels que ceux de Sweeney (2002) [18] et de Machanavajjhala et al. (2007) [14]. Son utilisation permet ainsi de comparer les résultats obtenus avec ceux rapportés dans la littérature.

Bien que le dataset ait été constitué à partir du recensement américain de 1994, il demeure aujourd'hui largement utilisé dans la recherche scientifique. Des travaux récents continuent de le mobiliser dans des domaines variés tels que l'anonymisation des données, l'équité algorithmique et l'intelligence artificielle explicable. En 2025, il a notamment été utilisé pour étudier de nouvelles approches de k-anonymat [6] et de nombreuses recherches en fairness continuent de l'employer comme benchmark de référence [16].

Le dataset regroupe 48 842 observations correspondant à des individus réels et contient 14 variables décrivant différentes caractéristiques démographiques, socio-économiques et professionnelles. Parmi ces variables figurent l'âge, le sexe, la race, le niveau d'éducation, la profession, le statut matrimonial ou encore le nombre d'heures travaillées par semaine. Le jeu de données comprend également une variable relative au revenu annuel (supérieur ou inférieur à 50 000 dollars), qui constitue dans cette étude l'attribut sensible à protéger.

3.3 Attributs retenus pour l'expérimentation

Certains attributs présents dans le dataset d'origine, tels que le niveau d'éducation exprimé sous forme numérique, le nombre d'heures travaillées par semaine ou encore le pays d'origine, n'ont pas été retenus. Leur exclusion vise à limiter la dimensionnalité du jeu de données et à concentrer l'analyse sur les quasi-identifiants les plus fréquemment mobilisés dans les travaux consacrés à la réidentification.

Le choix de ces variables permet de reproduire un scénario réaliste de publication de données dans lequel plusieurs informations démographiques et socio-économiques peuvent être exploitées pour tenter de réidentifier des individus. Cette configuration

TABLE 3.1 – Attributs retenus pour l'expérimentation

Attribut	Catégorie	Rôle dans l'analyse
Âge	Quasi-identifiant	Variable démographique fréquemment utilisée dans les attaques de réidentification.
Sexe	Quasi-identifiant	Information généralement publique qui, combinée à d'autres variables, peut réduire fortement l'anonymat.
Race	Quasi-identifiant	Variable démographique pouvant contribuer à l'identification et présenter une sensibilité particulière selon le contexte.
État civil	Quasi-identifiant	Caractéristique socio-démographique couramment disponible dans les bases administratives et publiques.
Profession	Quasi-identifiant	Information susceptible d'accroître l'unicité d'un individu lorsqu'elle est croisée avec d'autres attributs.
Revenu annuel (> 50 000 \$)	Attribut sensible	Information financière confidentielle dont la divulgation doit être empêchée.

est cohérente avec les travaux fondateurs de Sweeney (2002) [18] et de Machanavajjhala et al. (2007) [14].

3.4 Critères de comparaison retenus

Afin d'assurer la pertinence de la comparaison entre les techniques, les critères retenus s'appuient sur les principaux travaux de synthèse consacrés à l'évaluation des mécanismes de protection des données. Wagner et Eckhoff (2018) [19] proposent une revue exhaustive recensant plus de quatre-vingts métriques d'évaluation regroupées en plusieurs grandes catégories : protection de l'identité, protection des attributs sensibles, résistance aux attaques, utilité des données et coût computationnel. Plus récemment, Pau et al. (2025) [15] ont mis en évidence l'importance croissante de la dimension réglementaire dans le contexte du RGPD. Ces quatre critères m'ont semblé couvrir les dimensions essentielles du compromis confidentialité-utilité.

3.4.1 Risque de réidentification

Il correspond à la probabilité qu'un individu puisse être retrouvé ou distingué à partir des informations présentes dans un jeu de données, notamment lorsque celles-ci sont croisées avec des sources externes. Dans ce mémoire, ce risque est évalué à partir de l'approche proposée par Sweeney (2002) [18] : un enregistrement est considéré comme vulnérable lorsqu'il possède une combinaison unique de quasi-identifiants au sein du jeu de données. Cette mesure présente l'avantage d'être facilement calculable avant et après l'application des techniques d'anonymisation.

3.4.2 Utilité des données

Elle est évaluée selon deux dimensions complémentaires : la perte d'information engendrée par les opérations de généralisation ou de suppression, et l'homogénéité des groupes anonymisés. Dans le cas de la confidentialité différentielle, la littérature

évalue généralement l'utilité à travers l'impact du bruit ajouté sur les performances des modèles d'apprentissage automatique [9].

3.4.3 Complexité d'implémentation

Elle est appréciée à travers trois aspects principaux : les ressources logicielles nécessaires, le niveau d'expertise requis pour paramétrer correctement les mécanismes de protection, ainsi que l'effort computationnel associé. Cette dimension est particulièrement importante pour les organisations souhaitant mettre en place des dispositifs d'anonymisation sans disposer d'équipes spécialisées.

3.4.4 Conformité réglementaire

Elle est évaluée au regard des principes définis par le RGPD ainsi que des recommandations formulées par les autorités de protection des données, notamment la CNIL. L'objectif est de déterminer dans quelle mesure chaque technique est susceptible de satisfaire les exigences d'anonymisation irréversible ou de relever davantage de la pseudonymisation.

3.5 Processus d'implémentation

L'implémentation a été réalisée sous Python 3.11 au sein d'un environnement Jupyter Notebook, permettant de documenter de manière transparente l'ensemble des traitements effectués. J'ai délibérément choisi de ne pas utiliser de bibliothèques d'anonymisation spécialisées : travailler avec Pandas et NumPy uniquement m'a forcé à comprendre chaque étape de manière approfondie, et cela garantit une transparence totale des opérations réalisées.

Le protocole expérimental s'articule autour des étapes suivantes :

1. **Préparation des données** : importation du dataset UCI Adult, traitement des valeurs manquantes et sélection des attributs retenus pour l'analyse.
2. **Évaluation initiale du risque** : calcul du niveau de risque de réidentification sur les données originales à partir des quasi-identifiants sélectionnés.
3. **Application du k-anonymat** : définition des règles de généralisation, anonymisation progressive des quasi-identifiants et vérification du niveau de protection obtenu.
4. **Application de la l-diversity** : analyse de la diversité des attributs sensibles au sein des groupes anonymisés et ajustement des niveaux de généralisation lorsque cela est nécessaire.
5. **Application de la confidentialité différentielle** : ajout d'un bruit contrôlé aux données afin de limiter les risques de divulgation d'informations individuelles.
6. **Évaluation post-anonymisation** : calcul des indicateurs de confidentialité et d'utilité, comparaison des résultats obtenus et confrontation avec les conclusions issues de la littérature scientifique.

3.6 Environnement technique

3.6.1 Choix de l'environnement Python

L'ensemble de l'expérimentation a été réalisé sous **Python 3.11**, un langage aujourd'hui largement adopté dans les domaines de la science des données, de l'intelligence artificielle et de l'analyse statistique. Python bénéficie d'un écosystème riche de bibliothèques spécialisées ; dans le cadre de cette étude, les bibliothèques **Pandas**, **NumPy** et **Matplotlib** ont été mobilisées respectivement pour la manipulation des données, les calculs numériques et la visualisation des résultats.

Python se distingue également par sa lisibilité et sa simplicité d'utilisation, ce qui facilite la compréhension des traitements effectués et la vérification des résultats obtenus. Les mécanismes de k-anonymat, de l-diversity et de confidentialité différentielle peuvent ainsi être implémentés de manière transparente, sans recourir à des structures complexes. Ce choix permet de conserver une maîtrise totale des traitements effectués ; il facilite également la compréhension, la reproductibilité et la vérification des résultats, ce qui est essentiel dans un contexte académique.

Chapitre 4

Analyse comparative des techniques d'anonymisation

Ce chapitre présente les résultats de l'expérimentation menée sur le dataset UCI Adult Census Income. J'y présente successivement l'état initial du dataset, les effets observés après application de chaque technique, puis une analyse comparative structurée selon les quatre critères retenus. Je m'efforce tout au long de ce chapitre de relier chaque résultat aux travaux théoriques présentés dans les chapitres précédents, afin que l'expérimentation ne soit pas une simple démonstration technique, mais une véritable mise à l'épreuve des modèles de la littérature.

4.1 Diagnostic initial du dataset

Avant d'appliquer les différentes techniques d'anonymisation, il est nécessaire d'évaluer le niveau de confidentialité du jeu de données dans son état initial. Cette étape permet d'identifier les principaux risques auxquels les individus représentés dans la base sont exposés et de disposer d'un point de référence pour mesurer l'efficacité des mécanismes de protection.

4.1.1 Analyse des quasi-identifiants

Le dataset UCI Adult Census Income retenu comprend **45 222 enregistrements** après traitement des valeurs manquantes (suppression de 2 399 lignes). Les quasi-identifiants sélectionnés sont l'âge, le sexe, la race, l'état civil et la profession, tandis que le revenu annuel constitue l'attribut sensible dont la divulgation doit être évitée.

La première lecture du dataset brut m'a révélé quelque chose d'important : **3 835 individus, soit 8,5 %** du jeu de données, possèdent une combinaison unique de caractéristiques démographiques et socio-professionnelles. Cela signifie que ces individus pourraient être distingués du reste de la population et potentiellement réidentifiés par un attaquant disposant d'informations externes portant sur les mêmes variables. Ce résultat confirme l'observation de Sweeney (2002) [18] : la suppression des identifiants directs ne suffit pas.

L'étude de l'attribut sensible met en évidence une vulnérabilité supplémentaire et tout aussi préoccupante. Le jeu de données se répartit en **7 965 groupes distincts** selon les quasi-identifiants retenus, parmi lesquels **6 229 (78,2 %)** sont homogènes du point de vue du revenu. Dans ces groupes, tous les individus partagent la même

catégorie de revenu : c'est exactement l'attaque d'homogénéité formalisée par Machanavajjhala et al. (2007) [14].

Ces observations mettent en évidence deux risques distincts : un risque de réidentification lié à l'unicité de certaines combinaisons de quasi-identifiants, et un risque de divulgation de l'attribut sensible lié à l'homogénéité des groupes.

Ce résultat va dans le sens des travaux de Sweeney (2002) [18]. Elle a montré que la combinaison de quelques variables apparemment anodines pouvait suffire à réidentifier une personne lorsqu'elle est croisée avec des informations provenant de sources externes. Dans son étude, Sweeney a notamment montré qu'une grande partie de la population américaine pouvait être identifiée à partir de trois variables seulement : le code postal, la date de naissance et le sexe.

4.1.2 Analyse de l'attribut sensible

Il est également nécessaire d'évaluer le niveau de protection de l'attribut sensible retenu, à savoir le revenu annuel. Dans le dataset UCI Adult, cet attribut est représenté sous forme binaire et distingue les individus dont le revenu est supérieur à 50 000 dollars de ceux dont le revenu est inférieur ou égal à ce seuil.

L'analyse de la distribution des revenus montre que la majorité des individus appartiennent à la catégorie des revenus inférieurs ou égaux à 50 000 dollars, tandis qu'une proportion plus limitée déclare un revenu supérieur à ce seuil. Cette répartition déséquilibrée est cohérente avec les caractéristiques socio-économiques généralement observées dans les enquêtes de population.

Afin d'évaluer le risque de divulgation de l'information sensible, les individus ont été regroupés selon les quasi-identifiants retenus dans l'étude. Cette opération conduit à la formation de 7 965 groupes distincts. Parmi eux, 6 229 groupes, soit 78,2 %, présentent une homogénéité complète de l'attribut revenu. Autrement dit, tous les individus appartenant à ces groupes partagent la même catégorie de revenu.

Ce résultat met en évidence une vulnérabilité majeure du jeu de données. Même lorsqu'un individu ne peut pas être identifié de manière certaine, la connaissance de son groupe d'appartenance peut suffire à révéler une information sensible le concernant. Dans les groupes homogènes observés, un attaquant capable d'associer une personne à son groupe de quasi-identifiants pourrait déduire son niveau de revenu avec certitude.

Cette situation correspond à l'attaque d'homogénéité décrite par Machanavajjhala et al. (2007) [14]. Les auteurs ont montré qu'un groupe k -anonyme peut conserver un niveau élevé de risque lorsque tous ses membres possèdent la même valeur sensible. Dans ce cas, le k -anonymat protège l'identité des individus, mais ne protège pas nécessairement la confidentialité des informations qu'ils portent.

Le taux élevé de groupes homogènes observé dans les données initiales montre qu'un mécanisme complémentaire est nécessaire pour empêcher l'inférence du revenu. Ce constat justifie l'introduction de la l -diversity dans la suite de l'analyse, dont l'objectif est d'assurer une diversité minimale des valeurs sensibles dans chaque groupe anonymisé.

4.2 Résultats du k -anonymat

L'approche retenue repose sur l'application de règles de généralisation aux quasi-identifiants, sans qu'une valeur cible de k n'ait été définie préalablement. Après application des transformations, les enregistrements ont été regroupés selon leurs combinai-

sons de quasi-identifiants et le niveau de k a été déterminé *a posteriori* en identifiant la taille du plus petit groupe obtenu. Le k -anonymat n'a donc pas été imposé comme une contrainte préalable, mais observé comme une conséquence des choix de généralisation effectués. Cette démarche permet de mettre en évidence l'impact des opérations de généralisation sur le risque de réidentification sans recourir à des algorithmes d'optimisation complexes.

```
1 def generalize_age(age):
2     if age < 20: return '<20'
3     elif age < 30: return '20-29'
4     elif age < 40: return '30-39'
5     elif age < 50: return '40-49'
6     elif age < 60: return '50-59'
7     else: return '60+'
8
9 def generalize_marital_status(status):
10     if status in ['Married-civ-spouse',
11                  'Married-spouse-absent',
12                  'Married-AF-spouse']:
13         return 'Married'
14     elif status in ['Divorced', 'Separated', 'Widowed']:
15         return 'Separated/Divorced'
16     else:
17         return 'Single/Other'
18
19 def calculate_k_anonymity(df, quasi_ids):
20     groups = df.groupby(quasi_ids).size()
21     return groups.min(), groups # k minimal = niveau de
                                protection
```

Listing 4.1 – Hiérarchies de généralisation et vérification du k -anonymat

TABLE 4.1 – Effets du k-anonymat sur la confidentialité et l'utilité des données

Indicateur	Avant	Après k-anon	Évolution	Interprétation
Enreg. avec QI unique	3 835 (8,5 %)	≈ 0 %	Forte diminution	Risque de réidentification quasi éliminé
Risque de réidentification	Élevé	Très faible	Amélioration majeure	Individus ne peuvent plus être isolés
Valeurs distinctes — âge	73	6	Généralisation importante	Perte de précision démographique
Valeurs distinctes — état civil	7	3	Généralisation modérée	Réduction du niveau de détail
Valeurs distinctes — profession	14	4	Généralisation importante	Diminution de la granularité
Groupes homogènes sur le revenu	78,2 %	78,2 %	Aucune amélioration	Persistance du risque de divulgation de l'attribut sensible
Protection de l'identité	Faible	Élevée	Amélioration majeure	Objectif principal du k-anonymat atteint
Protection de l'attribut sensible	Faible	Faible	Inchangée	Le revenu reste facilement inférable dans de nombreux groupes
Utilité globale des données	Élevée	Moyenne à élevée	Légère dégradation	Les données restent exploitables malgré la généralisation

Le tableau montre que le k-anonymat remplit efficacement son objectif de réduction du risque de réidentification. La proportion d'enregistrements présentant une combinaison unique de quasi-identifiants passe de 8,5 % à une valeur proche de zéro. Cette amélioration a toutefois un coût en termes d'utilité des données. Afin de satisfaire la contrainte d'anonymat, plusieurs attributs ont dû être généralisés. Le nombre de valeurs distinctes de l'âge passe ainsi de 73 modalités à seulement 6 classes d'âge, tandis que l'état civil est réduit de 7 à 3 catégories et la profession de 14 à 4 catégories. Cette transformation réduit la précision des informations disponibles et limite certaines analyses fines.

L'un des résultats les plus importants concerne toutefois la persistance du problème d'homogénéité. Malgré la disparition du risque de réidentification, la proportion de groupes homogènes sur l'attribut sensible demeure inchangée à 78,2 %. En d'autres termes, le k-anonymat protège efficacement l'identité des individus mais ne protège pas nécessairement les informations sensibles qu'ils portent. Un attaquant capable d'identifier le groupe d'appartenance d'une personne pourrait encore déduire son niveau de revenu dans une très grande majorité des cas.

4.3 Résultats de la l-diversity

```

1 def generalize_age_l_diversity(age):
2     if age < 30: return '<30'
3     elif age < 50: return '30-49'
4     else: return '50+'
5
6 def generalize_race_l_diversity(race):
7     if race in ['White', 'Black']: return 'White-or-Black'
8     else: return 'Other'
9
10 # Verification : chaque groupe doit avoir >= L valeurs d'income
11 groups = df_l_diversity.groupby(quasi_id_l_diversity)
12 homogeneous = [g for name, g in groups
13                 if g['income'].nunique() < 2]

```

Listing 4.2 – Second niveau de généralisation pour la l-diversity

La valeur $L = 2$ a été retenue, cohérente avec la nature binaire de l'attribut sensible. L'objectif est de garantir que chaque groupe anonymisé contienne au moins une occurrence de chacune des deux catégories de revenu.

TABLE 4.2 – Effets de la l-diversity sur la protection des données et la granularité

Indicateur	Initial	Après k-anon	Après l-div (L=2)	Interprétation
Groupes homogènes	78,2 %	78,2 %	1-2 %	Réduction très importante du risque de divulgation
Valeurs distinctes — âge	73	6	3	Généralisation supplémentaire nécessaire
Valeurs distinctes — race	5	5	2	Regroupement des catégories raciales
Valeurs revenu par groupe	Variable	Souvent 1	≥ 2	Contrainte de diversité satisfaite
Risque d'attaque d'homogénéité	Élevé	Élevé	Faible	La majorité des groupes ne permet plus d'inférer directement le revenu
Niveau de protection de l'attribut sensible	Faible	Faible	Élevé	Amélioration significative de la confidentialité
Utilité des données	Élevée	Moyenne	Moyenne à faible	Protection renforcée mais perte d'information supplémentaire

Le tableau met en évidence le principal apport de la l-diversity. Alors que le k-

anonymat réduit le risque de réidentification, il laisse subsister un taux très élevé de groupes homogènes (78,2 %). L'introduction de la contrainte $L = 2$ permet de ramener la proportion de groupes homogènes de 78,2 % à environ 1–2 %, réduisant fortement le risque de divulgation du revenu.

Cette amélioration s'accompagne néanmoins d'une généralisation supplémentaire des quasi-identifiants. L'âge, qui avait déjà été regroupé en six classes dans le cadre du k -anonymat, est désormais ramené à trois grandes catégories (<30 ans, 30–49 ans et 50 ans et plus). De même, les cinq catégories raciales initiales sont fusionnées en deux groupes seulement. Cette généralisation plus importante entraîne une diminution de la granularité des données et donc une perte d'information supplémentaire. Ces résultats montrent le compromis entre confidentialité et utilité des données. En renforçant la diversité des valeurs sensibles, la l -diversity améliore significativement la protection de la vie privée, mais au prix d'une réduction de la précision des données disponibles pour l'analyse. Les informations sont exploitables, mais certaines analyses fines deviennent plus difficiles en raison du regroupement des catégories initiales.

4.4 Résultats de la confidentialité différentielle

```

1 import numpy as np
2
3 np.random.seed(42)
4
5 def laplace_mechanism(true_value, sensitivity, epsilon):
6     noise = np.random.laplace(0, sensitivity / epsilon)
7     return true_value + noise
8
9 # Requete : taux >50K par tranche d'age
10 # Sensibilite Delta_f = 1 (un individu dans un seul groupe)
11 epsilons = [0.1, 0.5, 1.0, 2.0, 5.0, 10.0]
12 for eps in epsilons:
13     noisy = laplace_mechanism(true_count,
14                               sensitivity=1,
15                               epsilon=eps)
16     erreur_L1 = abs(noisy - true_count) / true_count

```

Listing 4.3 – Mécanisme de Laplace appliqué à une requête agrégée

Dans cette expérimentation, un mécanisme de Laplace a été appliqué à la requête analytique principale : le taux de revenu supérieur à 50 000 dollars par tranche d'âge. Plusieurs valeurs du budget de confidentialité ϵ ont été testées afin d'évaluer l'impact du niveau de protection sur la précision des résultats.

Budget de confidentialité (ϵ). Le paramètre ϵ (epsilon) constitue le principal réglage de la confidentialité différentielle. Il détermine l'intensité du bruit ajouté aux résultats. Plus la valeur de ϵ est faible, plus la protection de la vie privée est élevée, mais plus les résultats publiés risquent d'être perturbés. À l'inverse, des valeurs élevées de ϵ réduisent la quantité de bruit injecté et améliorent la précision des résultats, au prix d'une protection moins forte.

Niveau de protection de la vie privée. Cette colonne indique le degré de confidentialité associé à chaque valeur de ϵ . Elle permet d'apprécier qualitativement la résistance du mécanisme face aux tentatives d'inférence ou de réidentification. Les

TABLE 4.3 – Impact du budget de confidentialité sur l'utilité des résultats

ε	Niveau de protection	Erreur relative	Utilité estimée	Interprétation
0,1	Très élevée	$< 1,0 \%$	$> 99,0 \%$	Protection maximale avec dégradation très limitée
0,5	Élevée	$< 0,2 \%$	$> 99,8 \%$	Excellent compromis confidentialité-utilité
1,0	Modérée	$< 0,1 \%$	$> 99,9 \%$	Impact du bruit pratiquement imperceptible
2,0	Modérée à faible	$\approx 0 \%$	$\approx 100 \%$	Résultats très proches des données réelles
5,0	Faible	$\approx 0 \%$	$\approx 100 \%$	Utilité maximale mais protection réduite
10,0	Très faible	$\approx 0 \%$	$\approx 100 \%$	Résultats quasiment identiques aux valeurs originales

niveaux présentés (très élevé, élevé, modéré ou faible) constituent une interprétation pratique du paramètre ε couramment utilisée dans la littérature.

Erreur relative observée. L'erreur relative mesure l'écart entre la valeur réelle de la statistique et la valeur obtenue après ajout du bruit de confidentialité différentielle. Elle est calculée à partir de la formule suivante :

$$\text{Erreur relative} = \frac{|\text{Valeur bruitée} - \text{Valeur réelle}|}{\text{Valeur réelle}}$$

Plus cette erreur est faible, plus les résultats publiés restent proches des données originales.

Utilité statistique estimée. Cet indicateur traduit la capacité des données protégées à conserver leur valeur analytique. Une utilité proche de 100 % signifie que les statistiques obtenues après anonymisation restent pratiquement identiques à celles calculées sur les données initiales. À l'inverse, une baisse de l'utilité traduit une dégradation progressive de la qualité de l'information disponible.

Les résultats montrent que même pour une valeur très faible de $\varepsilon = 0,1$, correspondant à un niveau élevé de protection de la vie privée, l'erreur relative observée demeure inférieure à 1 %. Lorsque ε augmente, l'amplitude du bruit ajouté diminue rapidement et les résultats obtenus deviennent pratiquement identiques aux valeurs réelles. À partir de $\varepsilon = 1$, l'erreur devient inférieure à 0,1 % et l'utilité statistique dépasse 99,9 %. Pour les valeurs les plus élevées du budget de confidentialité ($\varepsilon = 5$ et $\varepsilon = 10$), l'impact du bruit devient quasiment imperceptible et les statistiques produites sont pratiquement identiques à celles calculées sur les données originales.

Ces résultats s'expliquent principalement par la taille importante du dataset étudié. Le mécanisme de Laplace ajoute un bruit calibré à la sensibilité globale de la requête ($\Delta f = 1$). Dans le cas présent, chaque tranche d'âge regroupe plusieurs milliers d'individus. L'ajout de quelques unités de bruit reste donc négligeable par rapport aux effectifs observés, ce qui permet de préserver une très forte utilité statistique tout en garantissant un niveau élevé de confidentialité.

L'un des principaux avantages observés est l'absence de perte de granularité des données. Contrairement au k-anonymat et à la l-diversity, aucune généralisation des

variables n'est nécessaire. Les catégories d'âge, de profession ou de race conservent leur niveau de détail initial. La protection est obtenue non pas par transformation des données, mais par perturbation contrôlée des résultats produits à partir de celles-ci.

4.5 Analyse comparative des trois techniques

4.5.1 Comparaison selon la protection de la vie privée

TABLE 4.4 – Comparaison selon la protection de la vie privée

Critère	k-anonymat	l-diversity	DP Laplace
Réduction du risque de réidentification	Très élevée (≈ 0 % profils uniques)	Très élevée (≈ 0 %)	Non applicable aux données individuelles
Protection contre les attaques d'homogénéité	Faible (78,2 % de groupes homogènes)	Élevée (1-2 % de groupes homogènes)	Très élevée
Protection de l'attribut sensible	Limitée	Élevée	Très élevée
Résistance aux connaissances externes	Faible à moyenne	Moyenne	Élevée
Garantie formelle de confidentialité	Non	Non	Oui (ϵ -DP)
Niveau global de protection	Moyen	Élevé	Très élevé

Interprétation. Le k-anonymat réduit efficacement le risque de réidentification mais demeure vulnérable aux attaques d'homogénéité. La l-diversity corrige largement cette faiblesse en imposant une diversité minimale des valeurs sensibles. La confidentialité différentielle offre le niveau de protection le plus élevé grâce à sa garantie mathématique indépendante des connaissances détenues par un attaquant.

4.5.2 Comparaison selon l'utilité des données

TABLE 4.5 – Comparaison selon l'utilité des données

Critère d'utilité	k-anonymat	l-diversity	DP Laplace
Granularité de l'âge	73 $\rightarrow$ 6 catégories	73 $\rightarrow$ 3 catégories	73 catégories conservées
Granularité de la race	5 catégories conservées	5 $\rightarrow$ 2 catégories	5 catégories conservées
Granularité de l'état civil	7 $\rightarrow$ 3 catégories	7 $\rightarrow$ 3 catégories	7 catégories conservées
Granularité de la profession	14 $\rightarrow$ 4 catégories	14 $\rightarrow$ 4 catégories	14 catégories conservées
Erreur statistique introduite	Élevée (généralisation)	Très élevée (généralisation accrue)	$< 1\%$ même pour $\varepsilon = 0, 1$
Utilité analytique globale	Moyenne à élevée	Moyenne	Très élevée
Préservation des statistiques	Partielle	Faible à moyenne	Excellente ($> 99\%$)

Interprétation. Le k-anonymat entraîne une perte de précision modérée liée à la généralisation des variables. La l-diversity renforce la confidentialité mais au prix d'une dégradation supplémentaire de la granularité des données. À l'inverse, la confidentialité différentielle conserve les données dans leur forme initiale et introduit uniquement un bruit statistique très faible, ce qui lui permet d'obtenir la meilleure utilité globale.

4.5.3 Comparaison selon la complexité d'implémentation et la conformité réglementaire

TABLE 4.6 – Comparaison selon la complexité et la conformité réglementaire

Critère	k-anonymat	l-diversity	DP Laplace
Difficulté d'implémentation	Faible	Modérée	Modérée
Bibliothèques nécessaires	Pandas	Pandas	NumPy
Paramètres à définir	k	k et L	ε
Facilité d'interprétation	Très élevée	Élevée	Moyenne
Conformité RGPD	Partielle	Bonne	Très bonne
Test <i>singling out</i> (Art. 29)	Partiellement satisfait	Majoritairement satisfait	Satisfait
Test <i>linkability</i> (Art. 29)	Vulnérable	Protection améliorée	Très forte protection
Test <i>inference</i> (Art. 29)	Vulnérable	Protection renforcée	Très forte protection
Position vis-à-vis de la CNIL	Acceptable avec précautions	Plus robuste	Approche la plus favorable
Niveau global de conformité	Moyen	Élevé	Très élevé

Interprétation. Le k-anonymat demeure la technique la plus simple à mettre en œuvre et à comprendre. La l-diversity nécessite des traitements supplémentaires mais améliore sensiblement la protection des données sensibles. La confidentialité différentielle apparaît comme l'approche la plus robuste du point de vue réglementaire, car elle fournit une garantie mathématique de confidentialité compatible avec les exigences du RGPD, du Groupe Article 29 et des recommandations récentes des autorités de protection des données.

4.6 Discussion des résultats

TABLE 4.7 – Synthèse comparative des trois techniques

Critère	k-anonymat	l-diversity	DP Laplace
Réduction risque ré-identification	Très élevée (8,5 % $\rightarrow \approx 0$ %)	Très élevée (8,5 % $\rightarrow \approx 0$ %)	Non applicable aux données individuelles
Protection attribut sensible	Faible (78,2 % groupes homogènes)	Élevée (1–2 % groupes homogènes)	Très élevée (ϵ -DP)
Utilité des données	Moyenne à élevée (âge : 73 $\rightarrow$ 6)	Moyenne (âge : 73 $\rightarrow$ 3 ; race : 5 $\rightarrow$ 2)	Très élevée (< 1 % erreur)
Perte de granularité	Modérée	Élevée	Nulle
Complexité	Faible	Modérée	Modérée
Garantie formelle	Non	Non	Oui
Conformité RGPD	Acceptable sous conditions	Bonne	Très bonne
Appréciation globale	Bonne protection de l'identité ; protection limitée des attributs sensibles	Bon compromis protection-confidentialité	Meilleur compromis global

Si je devais tirer une leçon principale de cette expérimentation, ce serait celle-ci : **chaque technique répond à une problématique spécifique et aucune ne peut prétendre être universellement supérieure.** Le k-anonymat est efficace pour réduire le risque de réidentification, mais demeure vulnérable aux attaques visant les attributs sensibles. La l-diversity améliore significativement cette protection en réduisant les groupes homogènes de 78,2 % à environ 1–2 %, au prix d'une perte d'information supplémentaire. La confidentialité différentielle se distingue par sa capacité à préserver l'utilité statistique des données tout en offrant une garantie mathématique de confidentialité.

L'analyse comparative entre le k-anonymat et la l-diversity met clairement en évidence leur complémentarité. Le k-anonymat agit principalement sur le risque de réidentification, la l-diversity s'attaque spécifiquement au risque de divulgation de l'attribut sensible. Les résultats obtenus sur le dataset UCI Adult confirment ainsi les observations formulées par Machanavajjhala et al. (2007) [14].

Les résultats obtenus rejoignent également les conclusions de la littérature, qui considère la confidentialité différentielle comme l'une des approches les plus robustes pour la publication sécurisée de statistiques. Dans le cadre de cette expérimentation, elle apparaît comme la technique offrant le meilleur compromis entre protection et

utilité pour les analyses agrégées. Toutefois, cet avantage doit être nuancé : la confidentialité différentielle ne produit pas un jeu de données anonymisé directement exploitable comme le k-anonymat ou la l-diversity. Elle protège principalement les résultats d'analyse et nécessite un paramétrage rigoureux du budget de confidentialité ε .

4.7 Limites de l'expérimentation

Comme toute étude empirique, cette expérimentation présente certaines limites qui doivent être prises en compte lors de l'interprétation des résultats.

La première limite concerne le jeu de données utilisé. Le dataset UCI Adult constitue une référence largement utilisée dans la littérature, mais il s'agit d'un jeu de données issu du recensement américain de 1994. Les caractéristiques démographiques, économiques et sociales qu'il contient reflètent un contexte historique et géographique spécifique.

La deuxième limite est liée à la taille et à la nature du dataset. Avec plus de 45 000 enregistrements après nettoyage, UCI Adult constitue une base relativement importante pour une expérimentation académique. Cette caractéristique favorise notamment les performances de la confidentialité différentielle, puisque le bruit ajouté représente une faible proportion des effectifs observés. Les résultats pourraient être différents dans le cas de jeux de données de plus petite taille.

Une troisième limite concerne les paramètres retenus pour l'expérimentation. Les hiérarchies de généralisation utilisées pour le k-anonymat et la l-diversity ont été définies dans un objectif de clarté pédagogique et de reproductibilité. D'autres stratégies de généralisation ou des algorithmes d'optimisation plus avancés auraient pu conduire à des résultats différents en termes de perte d'information.

Enfin, cette expérimentation s'est volontairement concentrée sur trois techniques représentatives. D'autres méthodes récentes, telles que la t-closeness, les données synthétiques ou l'apprentissage fédéré, n'ont pas été intégrées à l'analyse. Leur prise en compte pourrait constituer une perspective intéressante pour de futurs travaux.

Conclusion générale

Les résultats obtenus montrent qu'aucune technique ne domine les autres sur l'ensemble des critères. Le k-anonymat se distingue par sa simplicité d'implémentation, la l-diversity par sa capacité à réduire efficacement les attaques d'homogénéité, tandis que la confidentialité différentielle offre le meilleur compromis global entre protection de la vie privée, utilité des données et conformité réglementaire. Ces résultats confirment l'idée largement admise dans la littérature selon laquelle le choix d'une technique d'anonymisation doit être effectué en fonction du contexte d'utilisation, du niveau de risque accepté et des objectifs poursuivis.

Bibliographie

- [1] Becker, B., & Kohavi, R. (1996). *Adult* [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5XW20>
- [2] Dwork, C., Kenthapadi, K., McSherry, F., Mironov, I., & Naor, M. (2006). Our Data, Ourselves : Privacy Via Distributed Noise Generation. In *Advances in Cryptology – EUROCRYPT 2006*, vol. 4004, Lecture Notes in Computer Science. Springer Berlin Heidelberg. https://doi.org/10.1007/11761679_29
- [3] Ficek, J., Wang, W., Chen, H., Dagne, G., & Daley, E. (2021). Differential Privacy in Health Research : A Scoping Review. *Journal of the American Medical Informatics Association*, 28(10), 2269–2276. <https://doi.org/10.1093/jamia/ocab135>
- [4] Fieschi, A., Hirmer, P., Stach, C., & Mitschang, B. (2025). Characterising and Categorising Anonymization Techniques : A Literature-Based Approach. *Proceedings of the 11th International Conference on Information Systems Security and Privacy*, 107–118. <https://doi.org/10.5220/0013379100003899>
- [5] Francis, P., Jurak, G., Leskoek, B., Otte, K., & Prasser, F. (2025). Comparison of Three Anonymization Tools for a Health Fitness Study. *Scientific Data*, 12(1), 1548. <https://doi.org/10.1038/s41597-025-05823-x>
- [6] Gajavalli, S. H. (2025). Human-Centered Interactive Anonymization for Privacy-Preserving Machine Learning : A Case for Human-Guided k-Anonymity. arXiv preprint. <https://doi.org/10.48550/ARXIV.2507.04104>
- [7] Halvorsen, L., Steffensen, S. L., Rafnsson, W., Kulyk, O., & Pardo, R. (2022). How Attacker Knowledge Affects Privacy Risks : An Analysis Using Probabilistic Programming. *Proceedings of the 2022 ACM IWSPA*, 55–65. <https://doi.org/10.1145/3510548.3519380>
- [8] Hartmann, S., & Ma, H. (Eds.). (2016). *Database and Expert Systems Applications*, vol. 9827, Lecture Notes in Computer Science. Springer International Publishing. <https://doi.org/10.1007/978-3-319-44403-1>
- [9] Hernandez, M., Osorio-Marulanda, P. A., Catalina, M., Loinaz, L., Epelde, G., & Aginako, N. (2025). Comprehensive evaluation framework for synthetic tabular data in health. *Frontiers in Digital Health*, 7, 1576290. <https://doi.org/10.3389/fdgth.2025.1576290>
- [10] Kalantari, K., Sankar, L., & Sarwate, A. D. (2018). Robust Privacy-Utility Tradeoffs Under Differential Privacy and Hamming Distortion. *IEEE Transactions on Information Forensics and Security*, 13(11), 2816–2830. <https://doi.org/10.1109/TIFS.2018.2831619>
- [11] Kara, B. C., Eyupoglu, C., & Karaku, O. (2025). (r, k, ϵ) -Anonymization : Privacy-Preserving Data Publishing Algorithm Based on Multi-Dimensional Outlier Detection, k-Anonymity, and ϵ -Differential Privacy. *IEEE Access*, 13, 70422–70435. <https://doi.org/10.1109/ACCESS.2025.3559410>

- [12] Kayem, A. V. D. M., et al. (2015). Adaptive Privacy-Preserving Data Publishing. *Lecture Notes in Computer Science*, Springer.
- [13] Kayem, A. V. D. M., et al. (2016). Privacy-Preserving Data Publication : Limits of the l-Diversity Approach. In Hartmann & Ma (Eds.), *DEXA 2016*, vol. 9827. Springer. <https://doi.org/10.1007/978-3-319-44403-1>
- [14] Machanavajjhala, A., Kifer, D., Gehrke, J., & Venkitasubramaniam, M. (2007). L-Diversity : Privacy beyond k-Anonymity. *ACM Transactions on Knowledge Discovery from Data*, 1(1), article 3. <https://doi.org/10.1145/1217299.1217302>
- [15] Pau, D., Bachot, C., Monteil, C., et al. (2025). Comparison of Anonymization Techniques Regarding Statistical Reproducibility. *PLOS Digital Health*, 4(2), e0000735. <https://doi.org/10.1371/journal.pdig.0000735>
- [16] Raftopoulos, G., Fazakis, N., Davrazos, G., & Kotsiantis, S. (2025). A Comprehensive Review and Benchmarking of Fairness-Aware Variants of Machine Learning Models. *Algorithms*, 18(7), 435. <https://doi.org/10.3390/a18070435>
- [17] Song, B., Pokhrel, S. R., Deng, M., et al. (2026). Digital Privacy Under Attack : Challenges and Enablers. *ACM Computing Surveys*, 58(4), 1–35. <https://doi.org/10.1145/3770853>
- [18] Sweeney, L. (2002). Achieving k-Anonymity Privacy Protection Using Generalization and Suppression. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, 10(05), 571–588. <https://doi.org/10.1142/S021848850200165X>
- [19] Wagner, I., & Eckhoff, D. (2019). Technical Privacy Metrics : A Systematic Survey. *ACM Computing Surveys*, 51(3), 1–38. <https://doi.org/10.1145/3168389>